

# SEMINÁRIO DE I.A.

---

Gustavo Molina de Souza

Luis Marcello Moraes Silva

Paulo Vitor de Queiroz Zanele

Prof. Dr. Geraldo Francisco Donegá Zafalon

# APPLICATION OF NON-LINEAR REGRESSION ANALYSIS AND ARTIFICIAL INTELLIGENCE ALGORITHMS FOR PERFORMANCE PREDICTION OF HARD ROCK TBMS

---

Alireza Salimi, Jamal Rostami, Christian Moormann,  
Andrea Delisio (2016)

# Agenda

- Introdução
- Fundamentação teórica
- Desenvolvimento
- Conclusão

# Introdução

- Em construção de túneis com rocha dura, se tornou padrão o uso de máquinas TBM.
- Necessidade de analisar o desempenho dessas máquinas
- Surgimento de diferentes modelos de previsão
- Divididos em dois grupos:
  - Modelos teóricos
  - Modelos empíricos

# Introdução

- Modelos teóricos:
  - Focam no estudo das forças da rocha em relação ao disco de corte
  - Encontrar equações de equilíbrio
  - Testes realizados em laboratórios
  - Taxa de penetração
  - Comportamento e fragmentação
  - Apresenta desvantagens
- Modelos empíricos

# Introdução

- Recentes análises sobre os túneis TBM
- Criação de um banco de dados
- Proposta do modelo QTBM
  - Análise de regressão não linear nos dados
  - Novos parâmetros de entradas
  - Porém, métricas importantes eram falhas
    - Carga de corte

# Introdução

- Em 2015, inclusão de inteligência artificial
- Queens Water Tunnel, em Nova York
- Tunelamento de rochas duras em Zagros, Irã
- Desenvolvimento de novas fórmulas empíricas
  - Regressão simples
  - Regressão múltipla não linear

# Introdução

- Utilização de técnicas de:
  - Otimização de enxames de partícula
  - Máquinas de vetores suporte
  - Sistema de inferência neuro-fuzzy adaptativo
- Em busca de:
  - Previsão da taxa de penetração da TBM
  - Avaliar tais modelos de desempenho
  - Comparação dos resultados





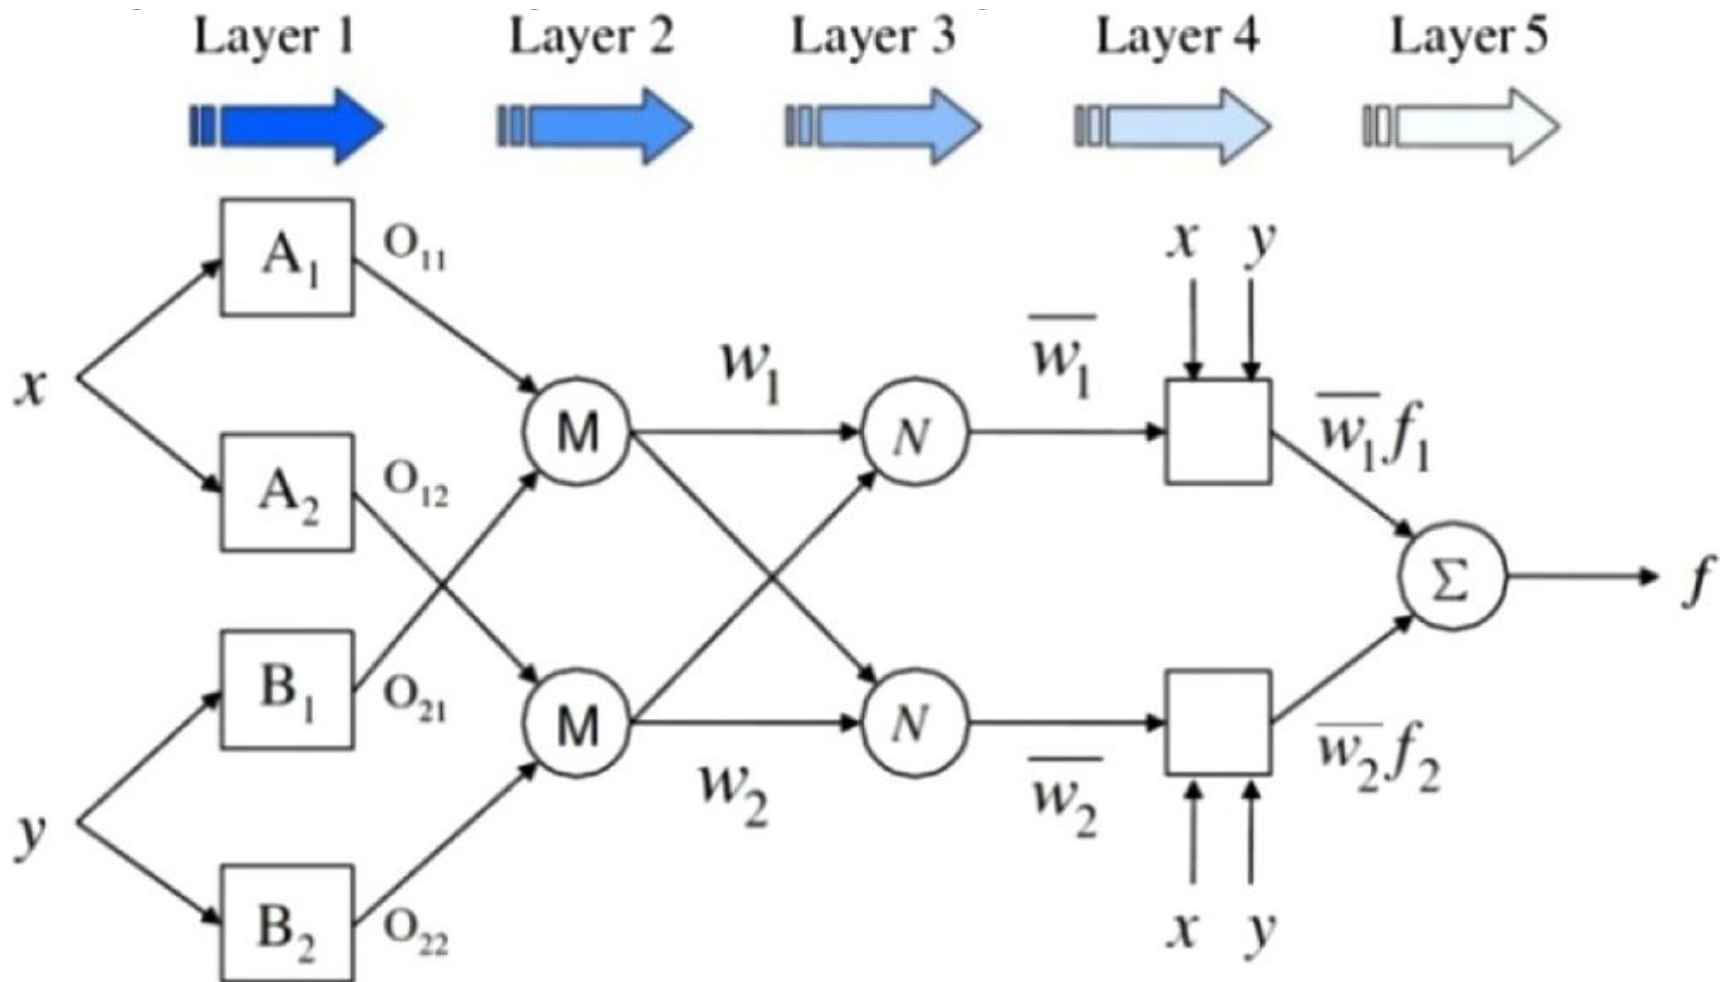
# Fundamentação teórica

- Otimização por enxames de partícula
  - Baseada em padrões da natureza
  - Realiza a movimentação de partículas dentro do espaço de busca
- Máquinas de vetores suportes
  - Métodos de aprendizado supervisionado
  - Reconhecimento de padrões, para análises de regressão

# Fundamentação teórica

- Sistema de inferência neuro-fuzzy adaptativo
  - Uma das primeiras arquiteturas
  - Processamento linguístico de um sistema de inferência
  - Capacidade de adaptação e aprendizagem
  - Encontrar parâmetros

# Fundamentação teórica



# Desenvolvimento

---

# Sobre o túnel de Zagros

- O túnel de Zagros, possui cerca de 49km
- Regular o fluxo de água, para planícies sudoestes do país
- Local de escavação possui uma complexidade geológica
- A construção do túnel foi dividida em lotes:
  - Lote 1A(14km)
  - Lote 1B(9km)
  - Lote 2(29km)

# Sobre o túnel de Zagros

- Profundidade média de 400m;
- Rota do túnel é localizada abaixo de um lençol freático;
- Estando acima cerca de 30m a 340m.

# Bancos de dados de desempenho TBM

- Dados obtidos nos lotes 1B e 2
- Durante a pré-construção e na construção
- Propriedades das rochas e a condição de água subterrânea
- Torque, impulso aplicado, RPM e taxa de penetração



# Bancos de dados de desempenho

## TBM

- Por meio da análise, chegou às seguintes equações:

$$ROP = \frac{l_b}{t_b} \quad (1)$$

ROP - Taxa média de penetração

$$P = \frac{ROP * 1000}{RPM * 60} \quad (2)$$

P - Penetração por revolução

$$FPI = \frac{F_n}{P} \quad (3)$$

FPI - Índice de penetração no campo

# Métodos de inteligência artificial

- Modelos baseados em Inteligência Artificial (IA) têm sido utilizados com sucesso por alguns pesquisadores para desenvolver modelos de previsão de desempenho das TBM (Alvarez Grima et al., 2000; Ghasemi et al., 2014; Mahdevari et al., 2014);
- Foram analisados dois métodos computacionais diferentes:
  - Inferência neuro-fuzzy (ANFIS);
  - Regressão vetorial de suporte (SVR).

# Adaptive neuro-fuzzy inference system (ANFIS)

- Combinação (rede neural e fuzzy) que fornece capacidades de previsão aprimoradas em comparação com o uso de uma única metodologia;
- Tornou-se popular na engenharia de rochas e solo, bem como na geologia de engenharia nos últimos anos (Gokceoglu et al., 2004; Yilmaz e Yuksek, 2009; Kucuck et al., 2011; Iphar, 2012).

# Support vector regression (SVR)

- Novo tipo de SVR;
- Mapeia não-linearmente os dados originais  $x$ , em um espaço de caractere dimensional mais alto e faz então uma regressão linear neste espaço (Vapnik, 1998);
- O problema foi resolvido com o uso do conjunto de software de aprendizado de máquina Weka, desenvolvido na Universidade de Waikato (Witten et al., 2011).

# Comparação

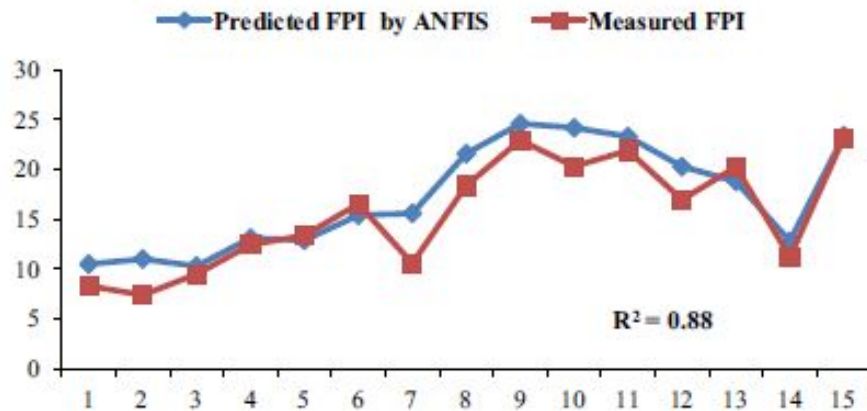


Fig. 11. Correlation coefficient for the ANFIS model for 20% test subsets.





Fig. 12. Correlation coefficient for the SVR model for 20% test subsets.

# Discussão e conclusões

- Uma comparação gráfica entre o FPI medido e o previsto na etapa de teste é mostrada na Figura 1, que indica que a previsão da SVR está mais próxima da FPI (*Field Penetration Index*) medida em contraste com a metodologia ANFIS.



**Fig. 14.** Comparação entre os valores medidos e previstos

# Discussão e conclusões

- Os parâmetros de entrada mais utilizados nos estudos anteriores para previsão do desempenho do TBM eram: resistência à compressão uniaxial da rocha intacta (usada por 70% dos modelos), distância e orientação das descontinuidades (usada por 50% dos modelos), o empuxo assumido por cortador (usado por 40% dos modelos) e o diâmetro da fresa (usado por 30% dos modelos);
- Foram utilizados conjuntos de dados limitados para previsão de desempenho com boa concordância em relação aos modelos anteriores.

# Discussão e conclusões

- Neste estudo, foi possível a seleção dos parâmetros de entrada com impacto máximo na análise da TBM;
- O foco deste estudo foi avaliar a aplicabilidade de vários modelos de AI em um conjunto limitado de dados do desempenho do TBM;
- Um trabalho adicional está em andamento para expandir o banco de dados a fim de incluir outros tipos de rochas e condições operacionais e melhorar os modelos disponíveis para aplicações gerais.



Obrigado!